

# Matriz de costos de modelos

Optimización de costos: qué modelo se usa por tarea (Gemini y Claude) y ahorro estimado – Ecosistema de Automatización IA

Este documento justifica **qué modelo se utiliza en cada tarea** del workflow y cuánto se ahorra frente a usar un único modelo premium para todo. La optimización no se limita a reducir tokens: combina **enrutamiento por tarea, escalado por complejidad, procesamiento por lotes y validaciones previas** que evitan llamar a la IA cuando no hace falta.

## 1. Criterios de selección

- **Complejidad de la tarea:** extracción y clasificación acotada frente a lectura densa o razonamiento con matices.
- **Volumen:** las tareas más frecuentes deben usar el modelo más económico que cumpla la calidad requerida.
- **Urgencia:** lo que no es inmediato se envía por API de lotes (Batch), con 50% de descuento.
- **Riesgo:** la respuesta final nunca depende de un modelo; la aprueba un abogado (HITL).
- **Costo por consulta aceptada,** no solo precio por token.

## 2. Precios de referencia (por millón de tokens)

Precios consultados el 1 de octubre de 2026, en dólares por millón de tokens (entrada / salida). El descuento de Batch es del 50% en ambos proveedores.

| Modelo                | Proveedor | Entrada   | Salida     | Batch (ent. / sal.) | Rol en la propuesta               |
|-----------------------|-----------|-----------|------------|---------------------|-----------------------------------|
| Gemini 3.5 Flash-Lite | Google    | US\$ 0,30 | US\$ 2,50  | US\$ 0,15 / 1,25    | Preclasificación estándar y lotes |
| Claude Sonnet 5.5     | Anthropic | US\$ 2,00 | US\$ 10,00 | US\$ 1,00 / 5,00    | Lectura densa                     |
| Claude Opus 5.5       | Anthropic | US\$ 4,00 | US\$ 20,00 | US\$ 2,00 / 10,00   | Casos críticos o ambiguos         |
| Claude Haiku 4.5      | Anthropic | US\$ 1,00 | US\$ 5,00  | US\$ 0,50 / 2,50    | Alternativa (no seleccionada)     |
| Gemini 3.6 Flash      | Google    | US\$ 1,50 | US\$ 7,50  | US\$ 0,75 / 3,75    | Referencia intermedia (no usada)  |

En Claude, las lecturas de caché de prompt cuestan el 10% del precio de entrada en Haiku y Sonnet, y 5% en Opus 5.5, y el descuento de Batch se acumula con el caché.

### 3. Matriz de decisión por tarea

| Tarea                                                                                          | Modelo / herramienta                                                                                | Justificación                                                                                                                                                                     | Costo relativo        |
|------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------|
| Extraer y normalizar el correo                                                                 | Nodo Código (n8n)                                                                                   | Es determinístico: no necesita IA.                                                                                                                                                | Nulo                  |
| Validar datos completos y detectar duplicados                                                  | IF + búsqueda en Airtable                                                                           | Se ejecuta <b>antes</b> de la IA: las consultas incompletas o repetidas no gastan tokens.                                                                                         | Nulo                  |
| <b>Preclasificación estándar</b> (subcategoría, prioridad, resumen, datos faltantes, borrador) | <b>Gemini 3.5 Flash-Lite</b>                                                                        | Tarea acotada con salida estructurada y alto volumen (~80% de los casos). Es el precio más bajo de la tabla: Haiku 4.5 costaría 3,3 veces más en entrada y 2 veces más en salida. | Muy bajo              |
| <b>Consultas largas o densas</b> (relato extenso, varios hechos, documentación pegada)         | <b>Claude Sonnet 5.5</b>                                                                            | Mejor comprensión de lectura larga y matices, con contexto de 1M tokens. Cuesta la mitad que Opus 5.5.                                                                            | Medio                 |
| <b>Casos ambiguos, de baja confianza o prioridad alta</b>                                      | <b>Claude Opus 5.5</b> (escalado)                                                                   | Segunda opinión solo para ~5% de los casos. El abogado sigue decidiendo.                                                                                                          | Alto, poco frecuente  |
| <b>Reprocesos masivos</b> (reclasificar histórico, informes periódicos)                        | <b>API de lotes:</b> Gemini 3.5 Flash-Lite Batch; Claude Sonnet 5.5 Batch si requiere lectura densa | No son urgentes y ambos proveedores aplican 50% de descuento.                                                                                                                     | Muy bajo              |
| Instrucciones fijas y esquema de salida repetidos                                              | Prompt caching (Claude)                                                                             | Las lecturas de caché cuestan una fracción del precio de entrada.                                                                                                                 | Reduce entrada        |
| Respuesta final al consultante                                                                 | Abogado (HITL)                                                                                      | Control obligatorio por gobernanza; ningún modelo la reemplaza.                                                                                                                   | Fuera del costo de IA |

#### Reglas de enrutamiento sugeridas

- Consulta o adjuntos de más de ~4.000 tokens: se envía a Sonnet 5.5.
- Resultado de Flash-Lite con prioridad alta y revisión requerida: segunda opinión con Opus 5.5.
- Trabajos no urgentes (más de una consulta acumulada, reprocesos): cola de lotes.

### 4. Supuestos de la estimación

Volumen supuesto: **300 consultas por mes** (editable). Tokens por consulta, incluyendo instrucciones del sistema y borrador de salida:

| Segmento       | Consultas | Entrada | Salida | Modelo en la estrategia          |
|----------------|-----------|---------|--------|----------------------------------|
| Estándar (80%) | 240       | 1.500   | 500    | Gemini 3.5 Flash-Lite            |
| Densas (15%)   | 45        | 6.000   | 700    | Claude Sonnet 5.5                |
| Críticas (5%)  | 15        | 3.000   | 700    | Flash-Lite + escalado a Opus 5.5 |

Total mensual: 0,675 millones de tokens de entrada y 0,162 de salida. Las críticas incluyen además una pasada previa de Flash-Lite (1.500 / 500 tokens).

## 5. Ahorro estimado por escenario

| Escenario                                    | Costo mensual (300 consultas) | Ahorro vs. base | Observación                                         |
|----------------------------------------------|-------------------------------|-----------------|-----------------------------------------------------|
| A. Todo con Claude Opus 5.5 (base)           | US\$ 5,94                     | -               | Calidad máxima, costo innecesario en tareas simples |
| B. Todo con Claude Sonnet 5.5                | US\$ 2,97                     | 50%             | Mitad del costo, pero sobre costo en lo estándar    |
| C. Todo con Gemini 3.5 Flash-Lite            | US\$ 0,61                     | 90%             | Más barato, riesgo de calidad en lectura densa      |
| <b>D. Estrategia por niveles (propuesta)</b> | <b>US\$ 1,68</b>              | <b>72%</b>      | Mejor equilibrio entre costo y calidad              |

La estrategia por niveles reduce el costo en un **72%** frente al escenario base, sin renunciar a Sonnet 5.5 en lectura densa ni a Opus 5.5 en los casos críticos.

## 6. Efecto del volumen

| Consultas por mes | Base (todo Opus 5.5) | Estrategia por niveles | Ahorro mensual | Ahorro anual |
|-------------------|----------------------|------------------------|----------------|--------------|
| 300               | US\$ 5,94            | US\$ 1,68              | US\$ 4,26      | US\$ 51      |
| 3.000             | US\$ 59,40           | US\$ 16,79             | US\$ 42,61     | US\$ 511     |
| 30.000            | US\$ 594,00          | US\$ 167,85            | US\$ 426,15    | US\$ 5114    |

Con 300 consultas por mes el ahorro absoluto es pequeño; el valor de la propuesta es que el diseño escala sin cambiar el porcentaje de ahorro.

## 7. Procesos masivos: API de lotes

Ejemplo: reclasificar un histórico de 3.000 consultas (1.500 tokens de entrada y 500 de salida cada una, es decir 4,5 y 1,5 millones de tokens).

| Opción                                 | Costo total      | Ahorro vs. Opus estándar |
|----------------------------------------|------------------|--------------------------|
| Claude Opus 5.5, tarifa estándar       | US\$ 48,00       | -                        |
| Claude Opus 5.5, Batch                 | US\$ 24,00       | 50%                      |
| Claude Sonnet 5.5, Batch               | US\$ 12,00       | 75%                      |
| Gemini 3.5 Flash-Lite, tarifa estándar | US\$ 5,10        | 89%                      |
| <b>Gemini 3.5 Flash-Lite, Batch</b>    | <b>US\$ 2,55</b> | <b>95%</b>               |

## 8. Riesgos y límites de la estimación

- **Tokens de razonamiento:** en Gemini se facturan como salida. La estimación no los incluye; conviene medirlos con los conteos reales de la API.

- **Calidad de Flash-Lite:** validar con 30 a 50 consultas reales y comparar el *costo por consulta aceptada* antes de fijar el enrutamiento.
- **Precios cambiantes:** los valores provienen de documentación de Anthropic y de comparadores de terceros (Google no se verificó directamente); confirmar en las páginas oficiales de cada proveedor antes de entregar.
- **Disponibilidad de modelos:** verificar el calendario de retiro de Claude Haiku 4.5 y los nombres exactos de los modelos de Gemini al implementar.
- **Volumen y tokens por consulta** son supuestos: reemplazarlos con los datos de la tabla Ejecuciones (Tokens entrada / Tokens salida).

## 9. Conclusión

---

Usar un modelo económico para lo repetitivo, un modelo de lectura profunda solo cuando el texto lo exige y un modelo superior únicamente como segunda opinión permite reducir el costo de IA alrededor de un **72%**. Las validaciones previas, el procesamiento por lotes y el caché de prompts suman ahorros adicionales, y la aprobación del abogado mantiene el control sobre la respuesta final.

La tabla Ejecuciones (campos Modelo IA, Tokens entrada y Tokens salida) ya registra los datos necesarios para medir el ahorro real mes a mes.